



UNIVERSIDADE FEDERAL DO TRIÂNGULO MINEIRO
INSTITUTO DE CIÊNCIAS TECNOLÓGICAS E EXATAS
DEPARTAMENTO DE ENGENHARIA ELÉTRICA

Jean Carlos Machado

**Previsão De Demanda E Preços De Energia Elétrica
Por Uma Cadeia Computacional Unificada Com
Aplicação Em Armazenamento**

Uberaba
2026

Jean Carlos Machado

**Previsão de Demanda e Preços de Energia Elétrica
por uma Cadeia Computacional Unificada com
Aplicação em Armazenamento**

Trabalho de conclusão de curso apresentado à
Universidade Federal do Triângulo Mineiro
como requisito parcial para graduação no curso
de Engenharia Elétrica.

Orientador: Prof. Dr. Thales Lima de Oliveira.

Banca Examinadora:

Prof. Dr. Thales Lima de Oliveira
Prof. Dr. Elder Vicente de Paulo Sobrinho
Prof. Dr. Arnaldo José Pereira Rosentino Junior

Uberaba
2026

ESPAÇO DESTINADO À FICHA CATALOGRÁFICA

Previsão de Demanda e Preços de Energia Elétrica por uma Cadeia Computacional Unificada com Aplicação em Armazenamento

1st Jean Carlos Machado

Departamento de Engenharia Elétrica

Universidade Federal do Triângulo Mineiro - UFTM

Uberaba, Brasil

d201810106@uftm.edu.br

Resumo—A liberalização dos mercados de energia elétrica tem ampliado a exposição de consumidores e agentes à incerteza de demanda e preços, tornando a previsão dessas variáveis um elemento central para a tomada de decisão econômica. Este trabalho propõe uma cadeia computacional unificada e reproduzível para previsão de séries temporais de energia elétrica, aplicada à demanda horária do sistema brasileiro e aos preços de energia em um mercado europeu liberalizado. São avaliados modelos estatísticos, de aprendizado de máquina e de aprendizado profundo sob uma estratégia de validação temporal do tipo *walk-forward*. Os resultados indicam que modelos baseados em árvores apresentam melhor desempenho na previsão de demanda, enquanto arquiteturas recorrentes profundas se destacam na previsão de preços. As previsões são utilizadas na simulação de um controlador simples de bateria, evidenciando que maior acurácia preditiva está diretamente associada a ganhos econômicos em estratégias de armazenamento de energia.

Palavras-chave—Armazenamento de energia; Mercado livre de energia; Previsão de demanda; Previsão de preços; Séries temporais; Python.

Abstract—The liberalization of electricity markets has increased the exposure of consumers and agents to demand and price uncertainty, making forecasting a key element for economic decision-making. This work proposes a unified and reproducible computational framework for electricity time series forecasting, applied to hourly demand of the Brazilian power system and to electricity prices in a liberalized European market. Statistical models, machine learning methods, and deep learning architectures are evaluated under a walk-forward validation strategy. The results show that tree-based models outperform others in demand forecasting, while deep recurrent architectures achieve superior performance in price forecasting. The forecasts are then used to simulate a simple battery controller, demonstrating that improved predictive accuracy is directly associated with economic gains in energy storage strategies.

Index Terms—Energy storage; Electricity price forecasting; Energy demand forecasting; Liberalized electricity markets; Time series forecasting; Python.

I. INTRODUÇÃO

A liberalização dos mercados de energia elétrica tem transferido aos consumidores e agentes a responsabilidade por decisões de compra, venda e armazenamento de energia, ampliando a exposição à incerteza de demanda e preços [1]. Vale notar que a previsão dessas variáveis torna-se fundamental para a operação econômica e a mitigação de riscos.

No Brasil, a expansão do mercado livre tem aumentado o número de agentes expostos à volatilidade de preços e à necessidade de planejamento de curto e médio prazo. Embora o mercado nacional ainda esteja em consolidação, experiências internacionais, como o mercado europeu, oferecem um referencial relevante para o estudo da formação de preços em ambientes plenamente liberalizados [1], [2]. Assim, este trabalho utiliza séries históricas de carga horária do Operador Nacional do Sistema Elétrico (ONS) [3] e séries de preços de curto prazo disponibilizadas pela *European Network of Transmission System Operators for Electricity* (ENTSO-E) [4].

Séries temporais de demanda e preços de energia caracterizam-se por elevada autocorrelação, múltiplas sazonalidades e, frequentemente, comportamento não estacionário. Essas propriedades impõem desafios à modelagem preditiva e tornam essencial a verificação da qualidade dos dados, incluindo integridade temporal, análise estatística descritiva e identificação de valores atípicos, cuja ausência pode comprometer a robustez e a interpretabilidade dos modelos [5].

Paralelamente, o crescimento do armazenamento distribuído, em especial sistemas baseados em baterias, amplia as possibilidades de arbitragem temporal de energia em mercados com elevada volatilidade de preços [6]. Embora a literatura e as bibliotecas *open-source* disponibilizem diversos modelos preditivos, diferenças em pré-processamento, validação temporal e definição do horizonte de previsão ainda dificultam comparações justas e a reproduzibilidade dos resultados.

Diante desse cenário, este trabalho propõe uma cadeia computacional unificada e reproduzível para previsão de séries temporais de energia elétrica, concebida para avaliar modelos de diferentes naturezas sob uma mesma estratégia de validação operacional. Essa cadeia corresponde a um fluxo padronizado



ICTE – Instituto de Ciências Tecnológicas e Exatas

Departamento de Engenharia Elétrica

Trabalho de Conclusão de Curso

Uberaba – Minas Gerais – Brasil

de etapas, que vai da aquisição e tratamento dos dados ao treinamento, geração das previsões e avaliação por métricas, garantindo comparabilidade entre os métodos. As previsões obtidas são utilizadas como entrada para um controlador simples de bateria, permitindo simular decisões de compra, venda e armazenamento de energia em um ambiente de mercado liberalizado [7].

II. FUNDAMENTAÇÃO TEÓRICA

Esta seção apresenta os fundamentos teóricos que embasam as análises e modelos adotados neste trabalho. São discutidas as características das séries temporais de energia elétrica, suas propriedades estatísticas, técnicas de decomposição e as principais classes de modelos preditivos empregadas na literatura.

A. Séries Temporais em Sistemas de Energia

Séries temporais são conjuntos de observações organizadas cronologicamente, geralmente coletadas em intervalos regulares, e são amplamente utilizadas no setor elétrico para representar variáveis como demanda, preços, geração e fluxos de energia. A análise dessas séries permite identificar padrões recorrentes, tendências de longo prazo e comportamentos sazonais relevantes para o planejamento e a operação de sistemas de energia [8]–[10].

Em aplicações energéticas, a elevada frequência temporal possibilita capturar ciclos associados ao comportamento de consumo, à operação do sistema e a fatores climáticos, ao custo de maior complexidade estatística, o que exige cuidados adicionais na modelagem e na avaliação preditiva.

B. Propriedades Estatísticas e Preparação das Séries de Energia

Séries temporais no contexto de distribuição de energia elétrica apresentam propriedades estatísticas que impõem desafios adicionais à previsão, como elevada autocorrelação, múltiplas sazonalidades (diárias, semanais e anuais) e, frequentemente, comportamento não estacionário. Essas características podem violar a hipótese de estacionariedade e a estabilidade da estrutura temporal ao longo do tempo, premisas frequentemente adotadas por modelos estatísticos clássicos (isto é, modelos estatísticos tradicionais e consolidados na literatura), como ARIMA e SARIMA. Quando tais efeitos não são mitigados por transformações apropriadas, como diferenciação e tratamento de sazonalidade, o desempenho preditivo pode ser comprometido [5].

A qualidade dos dados assume papel central nesse contexto, sendo fundamental verificar a regularidade do índice temporal (continuidade e frequência), a presença de valores ausentes e a ocorrência de valores atípicos, especialmente em séries de preços, que podem apresentar picos extremos associados a eventos de escassez ou falhas operativas. A análise estatística descritiva constitui uma etapa essencial para caracterizar essas propriedades e orientar decisões de modelagem [11].

A decomposição de séries temporais em componentes de tendência e sazonalidade é empregada como etapa de análise

exploratória, pois permite evidenciar padrões estruturais presentes nos dados e apoiar as decisões de modelagem adotadas neste trabalho. Para isso, utiliza-se a técnica *Seasonal-Trend decomposition using Loess* (STL) e, quando aplicável, sua extensão para múltiplas sazonalidades, *Multiple Seasonal-Trend decomposition using Loess* (MSTL) apoiando a escolha de estratégias de validação e a interpretação dos resultados obtidos pelos modelos [12], [13].

C. Modelos de Previsão e Armazenamento de Energia

Diversas classes de modelos têm sido propostas para a previsão de séries temporais de energia elétrica, refletindo diferentes compromissos entre interpretabilidade, flexibilidade e capacidade de capturar não linearidades. Modelos de referência, como *Naïve*(persistência), Média Móvel e *Drift*(extrapolação linear), são utilizados como baselines para comparação de desempenho.

Modelos estatísticos clássicos, como ARIMA, SARIMA e suas extensões com variáveis exógenas, são amplamente aplicados em séries temporais com dinâmica predominantemente linear e sazonalidade bem definida, frequentemente após transformações como diferenciação e termos sazonais. Em paralelo, métodos baseados em árvores de decisão, como Random Forest, XGBoost, CatBoost e LightGBM, destacam-se pela capacidade de explorar relações não lineares a partir de atributos derivados das séries temporais. Arquiteturas de aprendizado profundo, como LSTM, GRU, N-BEATS e DeepVAR, foram desenvolvidas para modelar diretamente dependências temporais complexas e podem apresentar vantagens em séries com alta variabilidade e mudanças abruptas, como picos e variações de regime [14].

No contexto de mercados de energia com formação competitiva de preços e variação temporal do valor da eletricidade, sistemas de armazenamento de energia por baterias ampliam as possibilidades de arbitragem temporal e gestão do consumo. A operação desses sistemas depende fortemente da dinâmica dos preços e da qualidade das previsões disponíveis, tornando a integração entre modelos preditivos e estratégias de controle um aspecto central na avaliação econômica do armazenamento [6], [15].

III. METODOLOGIA

Esta seção descreve a metodologia computacional adotada para a previsão de séries temporais de energia elétrica e para a simulação de decisões de compra, venda e armazenamento de energia. O procedimento foi estruturado como uma cadeia computacional unificada e reproduzível, composta por etapas padronizadas de preparação de dados, treinamento, geração de previsões e avaliação por métricas, conforme ilustrado na Figura 1. A comparação entre modelos é considerada justa porque todos os métodos são executados sob as mesmas condições experimentais: mesma base de dados, mesma segmentação temporal, mesma estratégia de validação do tipo *walk-forward* e o mesmo conjunto de métricas de desempenho.




Fig. 1. Visão geral da cadeia computacional unificada adotada neste trabalho, desde a aquisição dos dados até a aplicação das previsões no controlador.

A. Bases de Dados

Foram consideradas duas classes principais de séries temporais, analisadas como estudos de caso independentes. A primeira corresponde à demanda horária de energia elétrica do sistema brasileiro, obtida a partir das séries históricas de carga disponibilizadas pelo Operador Nacional do Sistema Elétrico (ONS), sendo utilizada como referência para a avaliação de modelos de previsão aplicados a séries de consumo. A segunda refere-se a séries horárias de preços de energia elétrica no mercado europeu, especificamente preços de curto prazo disponibilizados pela ENTSO-E, representativas de um ambiente de formação competitiva de preços.

Ressalta-se que as bases do ONS e da ENTSO-E representam sistemas distintos, com padrões sazonais e fatores externos próprios (por exemplo, clima, calendário e condições operativas locais). Dessa forma, elas não são combinadas entre si, sendo empregadas para avaliar a metodologia proposta em contextos diferentes de demanda e preço.

B. Pré-processamento, Estruturação e Validação Temporal

O pré-processamento teve como objetivo garantir a consistência temporal das séries analisadas e a adequação dos dados ao processo de modelagem. Foram tratados efeitos de transições de horário de verão e verificadas inconsistências no índice de tempo, incluindo lacunas temporais, duplicações de registros e desalinhamentos de frequência, de modo a assegurar a correta ordenação cronológica e uma amostragem horária consistente. As séries foram padronizadas para uma referência temporal comum (UTC) e reindexadas para uma malha horária regular, permitindo identificar explicitamente instantes ausentes. Valores ausentes foram tratados por remoção de janelas afetadas quando comprometiam o horizonte de previsão, evitando a introdução de distorções na modelagem.

Para modelos formulados como problemas de aprendizado supervisionado em formato tabular, as séries temporais foram transformadas por meio de engenharia de atributos, isto é, pela construção de variáveis explicativas a partir do histórico da série, incluindo defasagens temporais (*lags*), estatísticas móveis e variáveis de calendário representadas por codificação cíclica seno-cosseno [16]. Foram incluídas defasagens de curto prazo e sazonais, além de estatísticas móveis, com o objetivo de capturar padrões locais de variação. Para modelos

baseados em redes neurais recorrentes e arquiteturas profundas, os dados foram organizados como sequências temporais, segmentadas em janelas deslizantes definidas por um horizonte de observação e um horizonte de previsão, respeitando a ordem cronológica das amostras.

A divisão entre conjuntos de treinamento e teste foi realizada de forma estritamente temporal, evitando vazamento de informação. A avaliação dos modelos foi conduzida por meio de uma estratégia de validação do tipo *walk-forward* com realimentação diária, na qual o treinamento é atualizado progressivamente e as previsões são produzidas para períodos futuros, simulando um cenário operacional realista [16]. Em cada iteração, o modelo é ajustado com dados históricos disponíveis até o instante t e avaliado ao prever o horizonte imediatamente subsequente; em seguida, a janela é avançada e o procedimento é repetido.

C. Estratégias de Previsão Multi-Passo

A previsão multi-passo (*multi-step forecasting*) consiste em estimar uma sequência de valores futuros a partir de uma janela histórica de observações, permitindo gerar previsões para múltiplos instantes à frente dentro de um horizonte H . Esse tipo de formulação é particularmente relevante em aplicações operacionais, nas quais decisões são tomadas com base em projeções futuras ao longo de um intervalo de tempo [16].

Uma estratégia amplamente utilizada é a abordagem recursiva, na qual o modelo produz a previsão do próximo passo e, em seguida, essa previsão é realimentada como entrada para estimar os passos subsequentes. Embora simples de implementar, essa estratégia pode acumular erros ao longo do horizonte, especialmente em séries mais ruidosas ou com mudanças abruptas [16].

Alternativamente, pode-se empregar uma abordagem direta baseada em modelos do tipo *sequence-to-sequence* (Seq2Seq), na qual o modelo é treinado para mapear diretamente uma sequência de entrada em uma sequência completa de saídas futuras. Em termos práticos, considera-se uma janela de entrada de comprimento L , $\mathbf{x}_{t-L+1:t}$, e o modelo produz simultaneamente um horizonte de previsão com H passos, $\hat{\mathbf{y}}_{t+1:t+H}$, sem necessidade de realimentação passo a passo [17].

D. Modelos Avaliados

A cadeia computacional contempla diferentes classes de modelos preditivos, avaliados sob a mesma estrutura de dados e protocolo experimental:

- **Modelos de referência:** *Naïve*, Média Móvel e *Drift* [16];
- **Modelos estatísticos:** ARIMA, ARIMAX, SARIMA, SARIMAX e ETS [16], [18], [19], além do Prophet [20];
- **Modelos baseados em árvores:** Random Forest [21] e métodos de *gradient boosting* como XGBoost, CatBoost e LightGBM [22]–[24];
- **Redes neurais recorrentes:** LSTM e GRU [25], [26];
- **Modelos avançados de aprendizado profundo:** N-BEATS [27] e DeepVAR [28].

Para garantir comparabilidade entre métodos de naturezas distintas, todos os modelos foram implementados sob uma interface computacional padronizada, com uma classe dedicada por algoritmo, contemplando rotinas consistentes de treinamento e geração de previsões. A configuração e a parametrização de cada método seguiram recomendações da documentação oficial e práticas consolidadas na literatura, respeitando pressupostos e particularidades de cada família de modelos (por exemplo, hipóteses estruturais em modelos estatísticos e definição de janelas em modelos neurais).

Adicionalmente, quando aplicável, a seleção de hiperparâmetros foi realizada por otimização automatizada com orçamento controlado em número de avaliações por modelo, utilizando validação temporal no conjunto de treinamento. Embora o número de avaliações tenha sido mantido constante, o tempo total de treinamento variou entre algoritmos devido a diferenças inerentes de custo computacional. Ainda assim, a avaliação foi conduzida sob o mesmo protocolo de validação e sem qualquer ajuste baseado no conjunto de teste.

E. Configuração Experimental e Métricas

As previsões foram realizadas com resolução horária, utilizando horizonte de 24 horas e avaliadas ao longo de janelas consecutivas de 72 horas. A divisão entre conjuntos de treinamento e teste foi conduzida de forma estritamente temporal, e a avaliação seguiu a validação temporal proposta, simulando um cenário operacional no qual o modelo é atualizado progressivamente e aplicado para prever períodos futuros [16].

O desempenho preditivo dos modelos foi mensurado por meio das métricas RMSE, MAE, MAPE, sMAPE e coeficiente de determinação (R^2), apresentadas a seguir [16]. No caso da previsão de preços, métricas percentuais foram analisadas com cautela, uma vez que valores próximos de zero e variações abruptas podem torná-las instáveis. Esses comportamentos são esperados em séries de preços de curto prazo, nas quais podem ocorrer picos e mudanças de regime associadas a condições operativas do sistema [5]. Assim, a análise priorizou métricas absolutas para comparação entre modelos.

1) *Métricas de Avaliação*: Seja y_t o valor observado e $\hat{y}_t$ o valor previsto, com $t = 1, \dots, n$ e erro $e_t = y_t - \hat{y}_t$. As métricas utilizadas foram:

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |e_t| \quad (1)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n e_t^2} \quad (2)$$

$$\text{MAPE} = \frac{100}{n} \sum_{t=1}^n \left| \frac{e_t}{y_t} \right| \quad (3)$$

$$\text{sMAPE} = \frac{100}{n} \sum_{t=1}^n \frac{2 |e_t|}{|y_t| + |\hat{y}_t|} \quad (4)$$

$$R^2 = 1 - \frac{\sum_{t=1}^n (y_t - \hat{y}_t)^2}{\sum_{t=1}^n (y_t - \bar{y})^2} \quad (5)$$

em que $\bar{y}$ representa a média dos valores observados.

F. Otimização de Hiperparâmetros

Para modelos que não possuem mecanismos automáticos de ajuste, foi empregada otimização de hiperparâmetros por meio do *framework* Optuna [29]. A função objetivo foi definida como a minimização do erro quadrático médio no conjunto de validação, utilizando apenas o conjunto de treinamento sob particionamento temporal. O orçamento computacional foi controlado por um número fixo de avaliações (*trials*) por modelo, garantindo consistência no processo de ajuste, ainda que o tempo total de execução varie entre algoritmos devido ao custo computacional específico de cada método.

G. Controlador

Para avaliar o impacto operacional das previsões na tomada de decisão, foi adotado um controlador simples de bateria voltado à exploração de *arbitragem temporal*, isto é, carregar em períodos de menor preço e descarregar em períodos de maior preço. A simulação foi realizada em passos horários ($\Delta t = 1$ hora), com horizonte diário de $H = 24$ horas e execução ao longo de $N_{\text{days}} = 3$ dias (total de 72 horas). Para manter consistência dimensional, os dados foram convertidos para uma escala interna com potência em kW, energia em kWh e preço em EUR/kWh, incluindo a conversão de EUR/MWh para EUR/kWh por um fator 10^{-3} .

A bateria foi parametrizada com capacidade máxima $C_{\text{max}} = 30$ kWh, potência máxima $P_{\text{max}} = 6$ kW, estado inicial $\text{SOC}_0 = 50\%$ e eficiência global $\eta = 1$ (simplificação), respeitando os limites de carga/descarga e de estado de carga ao longo da simulação. O controlador utiliza uma estratégia determinística baseada em regras a partir das previsões de preço, de modo a isolar o efeito da qualidade preditiva sobre o desempenho econômico e evitar fatores de confusão associados a controladores mais complexos [6].

A decisão é construída com limiares definidos por quantis da distribuição de preços previstos no horizonte diário. Seja $\hat{p}_{t:t+H}$ o vetor de preços previstos para as próximas H horas, com quantis $q_{0.30}$ e $q_{0.70}$. Para cada instante, se $\hat{p}_t < q_{0.30}$ aciona-se carga; se $\hat{p}_t > q_{0.70}$ aciona-se descarga; caso contrário, a bateria permanece ociosa. Adicionalmente, foi aplicado um filtro de *break-even* para evitar decisões economicamente inviáveis. Estratégias baseadas em quantis são frequentemente utilizadas como referência em estudos de arbitragem com armazenamento por sua simplicidade e robustez [5], [30]. A simulação operacional foi aplicada sobre os períodos fora da amostra gerados, utilizando as previsões como entrada do controlador, permitindo comparar o impacto econômico associado a cada modelo preditivo sob o mesmo protocolo experimental.

Ressalta-se que o controlador é propositalmente simplificado e utilizado apenas como mecanismo de avaliação do impacto das previsões. Assim, efeitos adicionais da operação real de baterias, como eficiência variável com temperatura, degradação e restrições térmicas, não foram modelados nesta etapa.

H. Reprodutibilidade

Todos os experimentos foram implementados em Python, com registro sistemático de previsões, métricas e configurações dos modelos, assegurando a reprodutibilidade dos resultados e a extensibilidade do estudo. O código-fonte e os dados utilizados encontram-se disponíveis em repositório público em <https://github.com/machado-jean/TCC>.

IV. RESULTADOS E DISCUSSÃO

Esta seção apresenta os resultados obtidos com a cadeia computacional proposta para previsão de séries temporais de energia elétrica, considerando os estudos de caso de demanda e de preços. Inicialmente, é realizada uma análise exploratória (EDA) para caracterizar propriedades relevantes das séries e contextualizar as escolhas metodológicas. Em seguida, os modelos são comparados em avaliação fora da amostra, utilizando validação temporal do tipo *walk-forward* e um conjunto comum de métricas de desempenho. Por fim, o efeito das previsões é avaliado em um cenário operacional por meio da simulação de um controlador simples de bateria, permitindo quantificar o impacto operacional das previsões.

A. Análise Exploratória (EDA)

Foi conduzida uma análise exploratória para caracterizar propriedades temporais das séries e contextualizar os resultados preditivos. Essa etapa incluiu verificação da integridade do índice temporal, estatística descritiva, análise de autocorrelação (ACF/PACF), identificação de periodicidades via FFT e testes de estacionariedade (ADF e KPSS), considerando o recorte dos últimos 12 meses para consistência com o protocolo experimental.

1) *Demanda*: No recorte analisado, não foram identificadas lacunas, duplicações ou valores ausentes. Observou-se forte dependência temporal de curto prazo, com ACF em $t-1$ ($ACF \approx 0,97$) e $t-2$ ($ACF \approx 0,89$), além de recorrência diária em $t-24$ ($ACF \approx 0,82$). A FFT destacou periodicidades dominantes de 24 e 168 horas, compatíveis com ciclos diário e semanal, sustentando o uso de atributos derivados como *lags*, estatísticas móveis e variáveis de calendário. Os testes ADF e KPSS apresentaram evidências divergentes (ADF $p < 0,001$; KPSS $p \approx 0,01$), motivando a avaliação estritamente temporal via validação *walk-forward*.

2) *Preços*: No recorte dos últimos 12 meses, também não foram identificadas lacunas, duplicações ou valores ausentes. Porém observou-se alta dispersão e extremos (média $\approx 67,76$ EUR/MWh, desvio padrão $\approx 49,29$ EUR/MWh, mínimo $-118,01$ EUR/MWh e máximo $473,28$ EUR/MWh), indicando variação expressiva e justificando cautela com métricas percentuais. A autocorrelação permaneceu elevada em curto prazo (ACF em $t-1 \approx 0,95$) e com recorrência parcial em $t-24 \approx 0,80$, enquanto a FFT indicou periodicidades dominantes em 8736 horas e 12 horas. Assim como na demanda, ADF e KPSS produziram evidências divergentes (ADF $p < 0,001$; KPSS $p \approx 0,01$), reforçando a adoção de validação temporal *walk-forward*. A análise de atributos derivados também indicou multicolinearidade entre *features*,

especialmente entre estatísticas móveis e lags de curto prazo, reforçando a necessidade de padronização na etapa de modelagem.

B. Configuração Experimental

Os resultados apresentados foram obtidos a partir de previsões horárias com horizonte de 24 horas, avaliadas por meio de validação temporal do tipo *walk-forward* com realimentação diária, conforme descrito na Seção III. Em cada iteração, os modelos foram ajustados com dados até o instante de previsão e utilizados para estimar o horizonte subsequente.

As métricas de desempenho foram agregadas ao longo de janelas consecutivas de 72 horas (3 dias), obtidas a partir de três previsões sequenciais de 24 horas realizadas em dias consecutivos. Em cada dia, o modelo estimou diretamente o horizonte de 24 horas subsequente e, na iteração seguinte, foi atualizado utilizando os valores observados (reais) recém-disponíveis, sem realimentação de previsões. O desempenho foi quantificado por meio das métricas RMSE, MAE, MAPE, sMAPE e coeficiente de determinação (R^2). Para séries de preços, métricas percentuais (MAPE e sMAPE) foram interpretadas com cautela, devido à instabilidade quando os valores observados se aproximam de zero.

Todos os modelos foram avaliados sob as mesmas condições experimentais, mesma base de dados, mesma preparação, mesma segmentação temporal, mesmo protocolo de validação e mesmo conjunto de métricas, assim garantindo comparabilidade dos resultados.

C. Desempenho Preditivo

Nesta subseção são apresentados os resultados quantitativos obtidos na previsão de séries temporais de energia elétrica, considerando separadamente os problemas de previsão de demanda e de preço. Embora ambos tenham sido tratados sob a mesma cadeia computacional e protocolo experimental, as diferenças estruturais entre as séries motivam análises distintas.

1) *Previsão de Demanda Elétrica*: A Tabela I apresenta o desempenho dos modelos na previsão de demanda elétrica para um horizonte agregado de 72 horas, obtido a partir de três previsões sequenciais de 24 horas em dias consecutivos. Os modelos de referência (*baselines*) apresentaram maiores valores de erro e coeficientes de determinação negativos ou próximos de zero, sendo utilizados como limite inferior para comparação.

Entre os modelos estatísticos, ARIMAX e Prophet apresentaram melhora consistente em relação aos *baselines*, com redução de RMSE/MAE e aumento do coeficiente de determinação. No entanto, os menores erros foram obtidos pelos modelos baseados em árvores, com destaque para XGBoost, CatBoost e LightGBM, que apresentaram MAPE em torno de 3,6% e $R^2 \approx 0,89$, configurando o melhor desempenho global neste conjunto de testes.

Os modelos neurais recorrentes (LSTM e GRU) apresentaram desempenho intermediário, superando os *baselines*

e parte dos modelos estatísticos, porém com erros superiores aos melhores modelos baseados em árvores. Uma possível explicação é a sensibilidade dessas arquiteturas à parametrização e ao volume de dados disponível, especialmente quando comparadas a métodos baseados em árvores aplicados a dados tabulares com atributos derivados. Ressalta-se que a avaliação foi realizada estritamente fora da amostra por validação temporal do tipo *walk-forward*, o que reduz o risco de vazamento de informação e contribui para mitigar sobreajuste.

TABELA I
DESEMPENHO GLOBAL DOS MODELOS NA PREVISÃO DE DEMANDA (3 DIAS, 72 HORAS AVALIADAS)

Modelo	RMSE	MAE	MAPE	sMAPE	R^2
Baseline Média Móvel	5662.02	4884.94	0.1312	0.1228	-0.18
Baseline Naïve	5305.31	4590.19	0.1203	0.1158	-0.04
Baseline Drift	5303.72	4589.38	0.1203	0.1158	-0.04
ARIMA Nixtla	4506.04	3484.03	0.0932	0.0867	0.25
ARIMAX Nixtla	3552.48	2955.32	0.0738	0.0769	0.54
SARIMA Nixtla	4094.88	3069.63	0.0819	0.0763	0.38
SARIMAX Nixtla	4118.82	3082.91	0.0821	0.0764	0.38
ETS Auto	4826.62	3612.35	0.0972	0.0892	0.14
Prophet	3878.99	2936.40	0.0780	0.0733	0.45
Random Forest	1780.02	1355.71	0.0366	0.0359	0.88
XGBoost	1745.40	1330.99	0.0361	0.0354	0.89
CatBoost	1749.10	1326.05	0.0360	0.0353	0.89
LightGBM	1749.08	1326.53	0.0360	0.0353	0.89
LSTM	2693.82	1811.20	0.0508	0.0480	0.73
GRU	2955.78	2144.34	0.0588	0.0555	0.68
N-BEATS	4276.44	3081.75	0.0829	0.0766	0.33
DeepAR Nixtla	4611.63	3419.97	0.0907	0.0837	0.22

A Figura 2 ilustra a comparação entre a demanda real e a prevista ao longo de 72 horas utilizando o modelo XGBoost. Observa-se boa aderência às variações do sinal e captura da dinâmica geral da série ao longo do horizonte, com discrepâncias pontuais em instantes de maior variação.




Fig. 2. Comparação entre a demanda real e prevista ao longo de 72 horas utilizando o modelo XGBoost.

2) *Previsão de Preços de Energia*: A Tabela II apresenta o desempenho dos modelos na previsão de preços de energia elétrica para um horizonte agregado de 72 horas, obtido a partir de três previsões sequenciais de 24 horas em dias consecutivos. Em comparação com a demanda, observa-se maior variação nos erros ao longo dos modelos, refletindo a maior dificuldade da tarefa preditiva nesse conjunto de dados.

Métricas percentuais foram interpretadas com cautela, uma vez que a ocorrência de valores observados próximos de zero pode torná-las instáveis. Assim, a análise priorizou métricas absolutas (RMSE e MAE), complementadas por sMAPE e pelo coeficiente de determinação (R^2).

Os modelos de referência apresentaram desempenho limitado, caracterizando um patamar mínimo de comparação. Entre os modelos estatísticos, observa-se melhora consistente para SARIMA e SARIMAX em relação aos baselines, com redução de erro e aumento do coeficiente de determinação. Modelos baseados em árvores, como XGBoost, CatBoost e LightGBM, apresentaram desempenho competitivo, porém com variações entre métricas, indicando diferenças no tipo de erro minimizado em cada abordagem.

Os melhores resultados globais foram obtidos pelo modelo GRU, que apresentou o menor RMSE e o maior R^2 na janela analisada. De modo geral, os modelos neurais recorrentes (LSTM e GRU) apresentaram desempenho superior ao de boa parte dos modelos estatísticos e baseados em árvores neste cenário, sugerindo que a modelagem sequencial pode ser vantajosa para a série de preços no recorte temporal considerado. Ressalta-se, entretanto, que o desempenho de modelos neurais é sensível ao processo de ajuste e aos hiperparâmetros, de modo que os resultados devem ser interpretados no contexto do protocolo experimental utilizado.

TABELA II
DESEMPENHO GLOBAL DOS MODELOS NA PREVISÃO DE PREÇOS DE ENERGIA (3 DIAS, 72 HORAS AVALIADAS)

Modelo	RMSE	MAE	sMAPE	R^2
Baseline Média Móvel	46.84	36.90	0.7081	-0.21
Baseline Naïve	56.82	43.28	0.7245	-0.79
Baseline Drift	56.86	43.30	0.7245	-0.79
ARIMA Nixtla	45.50	36.58	0.7229	-0.15
ARIMAX Nixtla	42.25	34.84	0.7143	0.01
SARIMA Nixtla	34.26	24.91	0.6311	0.35
SARIMAX Nixtla	30.50	23.02	0.6271	0.49
ETS Auto	42.18	34.18	0.7108	0.02
Prophet	37.52	28.86	0.6637	0.22
Random Forest	33.03	27.49	0.8118	0.40
XGBoost	31.93	28.53	0.8033	0.44
CatBoost	31.74	26.50	0.8013	0.44
LightGBM	31.37	26.58	0.7987	0.46
LSTM	26.59	22.83	0.7331	0.61
GRU	22.23	19.80	0.6702	0.73
N-BEATS	39.86	28.56	0.6502	0.12
DeepAR Nixtla	29.62	21.94	0.7718	0.51

De forma complementar, a Figura 3 apresenta a comparação entre os preços reais e previstos ao longo de 72 horas utilizando o modelo GRU. Observa-se que o modelo acompanha a dinâmica geral da série e reage a variações abruptas em parte do horizonte, embora discrepâncias permaneçam em períodos de maior volatilidade.

De forma geral, os resultados mostram que o desempenho relativo dos modelos varia conforme a série analisada e a dinâmica do problema. Para a demanda, observou-se melhor desempenho dos modelos baseados em árvores com atributos derivados, enquanto para os preços os modelos neurais recorrentes apresentaram os melhores resultados no recorte




Fig. 3. Comparação entre os preços reais e previstos ao longo de 72 horas utilizando o modelo GRU.

avaliado. Esses resultados reforçam que não existe um modelo universalmente superior e que a escolha deve considerar as características da série e o objetivo da aplicação, motivando o uso de uma cadeia computacional unificada para avaliação comparativa sob um mesmo protocolo experimental.

D. Impacto Operacional do Controlador de Bateria

Para avaliar o impacto operacional das previsões obtidas, foi simulada a operação de um controlador simples de bateria ao longo de três dias consecutivos (72 horas). Como entrada do módulo de decisão, foram utilizados o modelo com melhor desempenho na previsão de preços (GRU). Em cada dia, as previsões de preços para as próximas 24 horas foram usadas para planejar ações horárias de carga/descarga, as quais foram posteriormente aplicadas sobre os valores reais observados, permitindo quantificar explicitamente o impacto do erro de previsão nas decisões de operação.

O sistema de armazenamento foi configurado com capacidade máxima $C_{\max} = 30$ kWh, potência máxima $P_{\max} = 6$ kW e estado inicial $SOC_0 = 50\%$, operando em passos horários ($\Delta t = 1$ h). A política de decisão foi baseada em limiares definidos por quantis dos preços previstos para o horizonte diário, utilizando $q_{0.30}$ como limiar inferior (carga) e $q_{0.70}$ como limiar superior (descarga), além de um filtro econômico de *break-even* para evitar decisões inviáveis. Restrições de potência e de estado de carga foram aplicadas a cada passo, garantindo $0 \leq SOC_t \leq C_{\max}$.

A Tabela III resume os principais indicadores econômicos e operacionais. O custo total de energia no período foi reduzido em 8,67 € (aproximadamente 4,8%) em comparação ao cenário sem armazenamento. Como o controlador prioriza a redução do custo por deslocamento temporal do consumo, a maior parcela do benefício foi associada ao autoconsumo, enquanto a receita por venda de energia foi nula no recorte analisado.

A Figura 4 apresenta a dinâmica integrada da operação ao longo do horizonte analisado. Observa-se que as decisões de carga e descarga respeitam os limites operacionais e geram variações coerentes no estado de carga, enquanto o benefício horário reflete o deslocamento do consumo para instantes

TABELA III
RESUMO DOS RESULTADOS ECONÔMICOS E OPERACIONAIS DA BATERIA

Métrica	Valor
Custo sem bateria (€)	180.68
Custo com bateria (€)	172.01
Economia percentual (%)	4.80
Horas em carga	22
Horas em descarga	16
Horas ociosa	34

de menor preço. O benefício acumulado evidencia o ganho operacional ao longo do período, ainda que parte das ações de carga represente um custo imediato que é compensado posteriormente.




Fig. 4. Dinâmica temporal integrada da operação do sistema com armazenamento: (a) ações horárias de carga/descarga limitadas por $P_{\max}$, (b) evolução do estado de carga (SOC), (c) demanda do sistema, (d) benefício econômico horário e (e) benefício acumulado ao longo do horizonte analisado.

Ressalta-se que a simulação foi conduzida sob hipóteses simplificadoras, como eficiência global unitária e ausência de degradação e restrições térmicas, não representando todos os efeitos presentes em sistemas reais. Assim, os resultados devem ser interpretados como uma estimativa do impacto relativo das previsões em um ambiente controlado, compatível com o objetivo principal deste trabalho de avaliar a cadeia computacional de previsão e sua aplicação operacional.

V. CONCLUSÃO

Este trabalho apresentou uma cadeia computacional unificada e reprodutível para previsão de séries temporais de energia elétrica, aplicada a estudos de caso de demanda e

de preços de curto prazo. A metodologia integrou etapas de análise e pré-processamento, modelagem e validação temporal, permitindo comparar diferentes classes de modelos sob um protocolo experimental comum. As previsões obtidas foram posteriormente utilizadas em um cenário operacional por meio da simulação de um controlador simples de bateria, com regras determinísticas e interpretáveis.

Os resultados obtidos indicam que o desempenho relativo dos modelos varia conforme a série analisada e o recorte temporal considerado. Na previsão de demanda, os menores erros foram observados em modelos baseados em árvores, enquanto na previsão de preços o melhor desempenho no conjunto avaliado foi obtido por modelos neurais recorrentes, com destaque para a GRU. A avaliação operacional mostrou ainda que previsões mais acuradas podem produzir ganhos econômicos mensuráveis mesmo quando empregadas em estratégias de controle simples, reforçando a utilidade de incorporar métricas operacionais além das métricas preditivas.

Como perspectivas futuras, destacam-se a incorporação explícita de incerteza nas previsões, a avaliação de estratégias de controle mais sofisticadas e a aplicação da metodologia a cenários adicionais, incluindo dados reais de consumidores no mercado livre brasileiro.

AGRADECIMENTOS

O autor agradece à sua companheira, Athany, pelo apoio e incentivo ao longo de todo o processo de desenvolvimento deste trabalho, e aos seus pais, Aparecida e Joel, pelo suporte e dedicação durante toda a graduação.

Agradece, de forma especial, ao Prof. Dr. Thales, pela orientação, disponibilidade e contribuições fundamentais para a realização deste trabalho. Estende seus agradecimentos a todos os professores que contribuíram para sua formação acadêmica.

Por fim, agradece à Universidade Federal do Triângulo Mineiro (UFTM) pelo ambiente e pelas condições oferecidas ao longo de sua formação.

REFERÊNCIAS

- [1] P. L. Joskow, "Lessons learned from electricity market liberalization," *The Energy Journal*, vol. 29, no. 2_suppl, pp. 9–42, 2008, special Issue: The Future of Electricity: Papers in Honor of David Newbery. [Online]. Available: <https://economics.mit.edu/sites/default/files/2022-09/Lessons%20Learned%20from%20Electricity%20Market%20Liberalization.pdf>
- [2] A. C. S. R. Filho, "A evolução do mercado livre de energia no brasil: perspectivas e desafios," *Seven Publicações Acadêmicas*, 2023. [Online]. Available: <https://sevenpubl.com.br/anais7/article/download/6828/12280/27255>
- [3] O. N. do Sistema Elétrico (ONS), "Dados de demanda energética," <https://dados.ons.org.br/>, 2025, oNS data platform.
- [4] E. N. of Transmission System Operators for Electricity (ENTSOE), "Transparency platform," <https://transparency.entsoe.eu/>, 2025, eNTSOE data platform.
- [5] R. Weron, "Electricity price forecasting: A review of the state-of-the-art with a look into the future," *International Journal of Forecasting*, vol. 30, no. 4, pp. 1030–1081, 2014.
- [6] B. Zakeri and S. Syri, "Electrical energy storage systems: A comparative life cycle cost analysis," *Renewable and Sustainable Energy Reviews*, vol. 42, pp. 569–596, 2015.
- [7] C. Fraunholz, E. Kraft, D. Keles, and W. Fichtner, "Advanced price forecasting in agent-based electricity market simulation," *Applied Energy*, vol. 290, p. 116688, 2021.
- [8] G. E. P. Box, G. M. Jenkins, and G. C. Reinsel, *Time Series Analysis: Forecasting and Control*, 4th ed. Wiley, 2008.
- [9] P. J. Brockwell and R. A. Davis, *Introduction to Time Series and Forecasting*, 2nd ed., ser. Springer texts in statistics. Springer, 2002.
- [10] R. H. Shumway and D. S. Stoffer, *Time Series Analysis and Its Applications: With R Examples*, 4th ed., ser. Springer texts in statistics. Springer, 2017.
- [11] U. Javed, K. Ijaz, M. Jawad, E. Ansari, N. Shabbir, L. Kütt, and O. Husev, "Exploratory data analysis based short-term electrical load forecasting: A comprehensive analysis," *Energies*, vol. 14, p. 5510, 2021. [Online]. Available: <https://doi.org/10.3390/en14175510>
- [12] R. B. Cleveland, W. S. Cleveland, J. E. McRae, and I. Terpenning, "Stl: A seasonal-trend decomposition procedure based on loess," *Journal of Official Statistics*, vol. 6, no. 1, pp. 3–73, 1990.
- [13] K. Bandara, R. J. Hyndman, and C. Bergmeir, "Mstl: A seasonal-trend decomposition algorithm for time series with multiple seasonal patterns," *arXiv preprint arXiv:2107.13462*, 2021. [Online]. Available: <https://arxiv.org/abs/2107.13462>
- [14] J. Lago *et al.*, "Forecasting day-ahead electricity prices: A review of state-of-the-art methods," *Renewable and Sustainable Energy Reviews*, vol. 150, p. 111402, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0306261921004529>
- [15] T. Mercier, "The value of electricity storage arbitrage on day-ahead markets," *Energy Economics*, vol. 120, p. 106507, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S0140988323002190>
- [16] R. J. Hyndman and G. Athanasopoulos, *Forecasting: principles and practice*, 3rd ed. Melbourne, Australia: OTexts, 2021. [Online]. Available: <https://otexts.com/fpp3/>
- [17] I. Sutskever, O. Vinyals, and Q. V. Le, "Sequence to sequence learning with neural networks," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2014.
- [18] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5th ed. Wiley, 2015.
- [19] J. Durbin and S. J. Koopman, *Time Series Analysis by State Space Methods*, 2nd ed. Oxford University Press, 2012.
- [20] S. J. Taylor and B. Letham, "Forecasting at scale," *The American Statistician*, 2018.
- [21] L. Breiman, "Random forests," *Machine Learning*, 2001.
- [22] T. Chen and C. Guestrin, "Xgboost: A scalable tree boosting system," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.
- [23] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, and A. Gulin, "Catboost: unbiased boosting with categorical features," *arXiv preprint arXiv:1706.09516*, 2018.
- [24] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "Lightgbm: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [25] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, 1997.
- [26] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning phrase representations using rnn encoder–decoder for statistical machine translation," *arXiv preprint arXiv:1406.1078*, 2014. [Online]. Available: <https://arxiv.org/abs/1406.1078>
- [27] B. N. Oreshkin, D. Carpio, N. Chapados, and Y. Bengio, "N-beats: Neural basis expansion analysis for interpretable time series forecasting," *International Conference on Learning Representations (ICLR)*, 2020. [Online]. Available: <https://arxiv.org/abs/1905.10437>
- [28] D. Salinas, V. Flunkert, and T. Januschowski, "Deepvar: A multivariate deep learning model for probabilistic forecasting," *arXiv preprint*, 2019.
- [29] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2019.
- [30] A. J. Conejo, M. Carrion, and J. M. Morales, *Decision Making Under Uncertainty in Electricity Markets*, ser. International Series in Operations Research & Management Science. Springer, 2010. [Online]. Available: <https://link.springer.com/book/10.1007/978-1-4419-7421-1>